

APRENDIZAGEM COMPUTACIONAL



KNN EM CONTEXTOS DE CLASS IMBALANCE

**CATARINA AGUIAR (202205932); JOÃO
RAPOSO(202210331); RODRIGO COELHO (202208009)**

GRUPO PL2_G10

4 JUNHO 2025

SUMÁRIO

OBJETIVO

Avaliar o desempenho do KNN em contextos de classificação binária com forte desequilíbrio de classes.

ABORDAGEM

Implementação do KNN, análise de desempenho em datasets desequilibrados, propostas de melhoria do algoritmo.

RESULTADOS

Os modelos modificados apresentam resultados diversificados

INTRODUÇÃO


Neste projecto exploramos o impacto da class imbalance na performance do algoritmo K-Nearest Neighbors

Testamos o algoritmo em cenários desbalanceados e alteramos o algoritmo numa tentativa de melhorar os resultados.

K-NEAREST NEIGHBOR

KNN é um algoritmo de classificação supervisionada que classifica uma nova instância com base na classe mais frequente entre os K vizinhos mais próximos

Sentível a ruído e mais importante a distribuições desbalanceadas



CARACTERISTICAS DOS DADOS



O desequilíbrio de classes ocorre quando uma classe é muito mais frequente do que a outra.

Problema no KNN: os vizinhos mais próximos tendem a ser da classe majoritária, prejudicando a detecção da classe minoritária.



O desequilíbrio de classes ocorre quando uma classe é muito mais frequente do que a outra.

TRATAMENTO DE DADOS

Normalização o
nome da coluna
alvo para o
nome CLASS

Apresentação
de valores
únicos

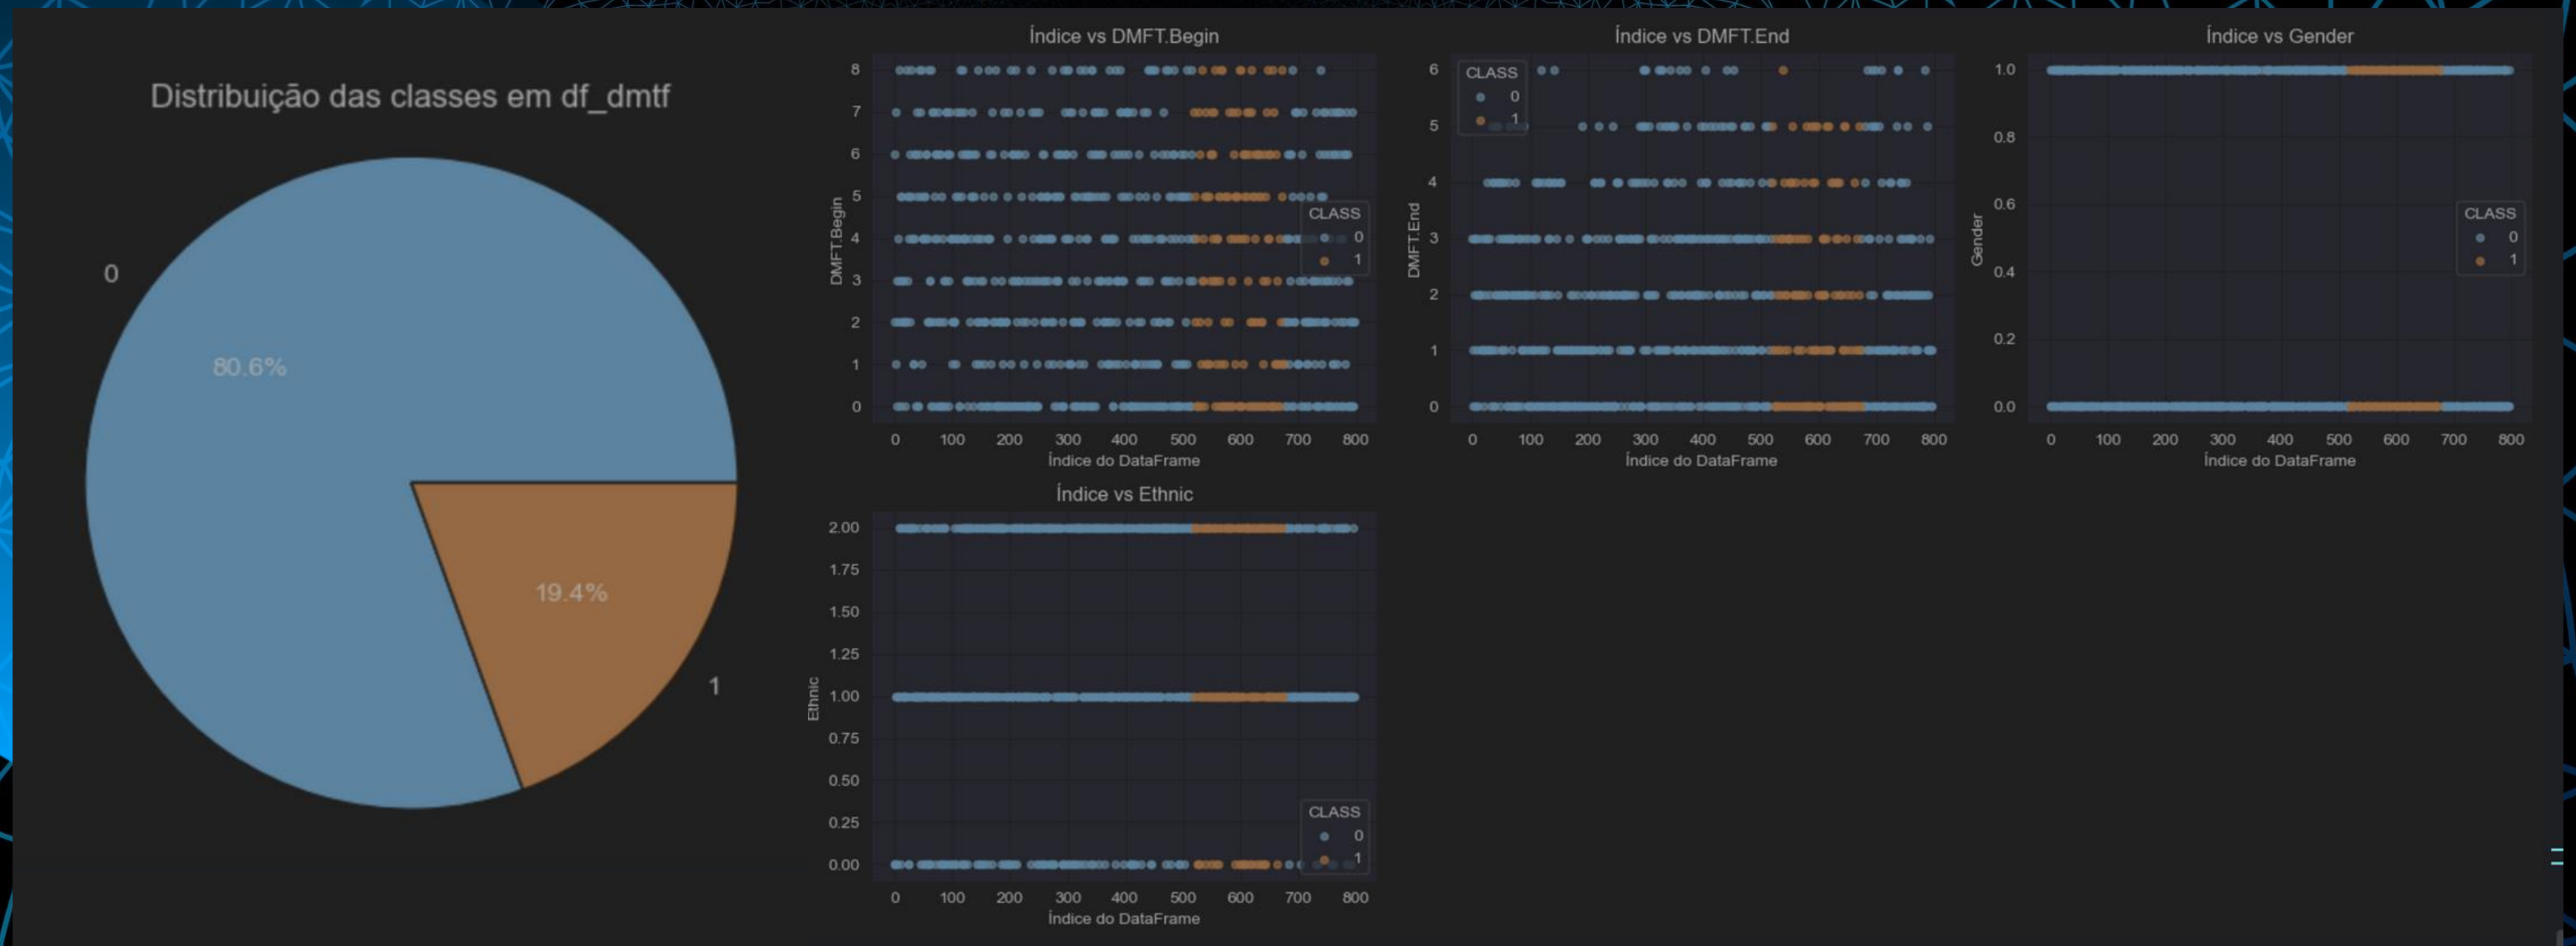
Contabilizar o
número de
instâncias

Verificação da
distribuição das
classes

Distribuição
das classes
de forma
visual

KNN EM CONTEXTOS DE CLASS IMBALANCE

TRATAMENTO DE DADOS



PROPOSTA DE ALTERAÇÃO DOS ALGORITMOS

1

Agregação ponderada por distância e frequência da classe

Modifica a forma como os vizinhos contribuem para a decisão do modelo, atribuindo pesos inversamente proporcionais à distância e à frequência da classe de cada vizinho.

O objetivo é reduzir a influência excessiva da classe majoritária, mesmo quando esta domina localmente o espaço de atributos.

2

Oversampling com jitter da classe minoritária

Nesta abordagem, aumentamos a representatividade da classe minoritária através da geração de exemplos sintéticos. Estes são obtidos aplicando pequenas perturbações (jitter) a exemplos reais da classe rara. O objetivo é equilibrar a distribuição das classes antes do treino.

KNN EM CONTEXTOS DE CLASS IMBALANCE

ESTUDO EMPÍRICO

Dataset usado para testes: DMTS

Splits de treino/teste:
0.3

Métricas usadas:
Accuracy, Precision,
Recall, F1

K = 3

```
df_dmtf.head()
```

✓ [56] < 10 ms

5 rows ▾ 5 rows × 5 cols


↕	<u>123</u> DMFT.Begin	↕	<u>123</u> DMFT.End	↕	<u>123</u> Gender	↕	<u>123</u> Ethnic	↕	<u>123</u> CLASS	↕
0		6		3		0		0		0
1		2		1		1		0		0
2		1		0		0		0		0
3		7		2		0		1		0
4		3		3		1		1		0

KNN EM CONTEXTOS DE CLASS IMBALANCE

AGREGAÇÃO PONDERADA POR DISTÂNCIA E FREQUÊNCIA DA CLASSE

Sem
balanceamento
prévio dos dados

↕	Métrica	↕	KNN Clássico	↕	KNN Novo	↕
0	Accuracy		0.812500		0.558333	
1	Precision		0.028571		0.514286	
2	Recall		0.083333		0.168224	
3	F1-Score		0.042553		0.253521	



KNN EM CONTEXTOS DE CLASS IMBALANCE





OVERSAMPLING COM JITTER DA CLASSE MINORITÁRIA

Com
balanceamento
dos dados

↕	Métrica	↕	KNN Clássico	↕	KNN com Jitter	↕
0	Accuracy		0.812500		0.533333	
1	Precision		0.028571		0.428571	
2	Recall		0.083333		0.140187	
3	F1-Score		0.042553		0.211268	



DMTF — Barras



DISCUSSÃO

AGREGAÇÃO PONDERADA POR DISTÂNCIA
E FREQUÊNCIA DA CLASSE

A MODIFICAÇÃO COMPENSA?

Apesar da diminuição na accuracy, observamos um aumento significativo na precision, recall e F1-score.

Esta melhoria era esperada, já que o objetivo era melhorar a detecção da classe minoritária, mesmo que isso implique sacrificar a taxa global de acerto.

Logo a modificação compensa

OVERSAMPLING COM
JITTER DA CLASSE MINORITÁRIA

A MODIFICAÇÃO COMPENSA?


Sim, a modificação compensa.

Apesar de uma ligeira queda na accuracy, houve uma melhoria clara na precision, recall e F1-score para a classe minoritária, o que é crucial em contextos desbalanceados,.

DISCUSSÃO

COMPARANDO AS DUAS ABORDAGENS, A AGREGAÇÃO PONDERADA COMPENSOU MAIS.

- Agregação ponderada apresentou melhor equilíbrio e melhor resultados entre precision, recall e F1-score, com menor risco de overfitting
- Não introduz dados artificiais - solução mais **robusta e fiável**



FUTURO

No futuro poderíamos explorar a combinação das duas estratégias desenvolvidas: aplicar oversampling com jitter para equilibrar a distribuição de classes e, em simultâneo, utilizar a agregação ponderada por distância e frequência da classe durante a classificação.

CONCLUSÕES

O KNN revelou-se sensível ao desequilíbrio de classes, como esperado.

A agregação ponderada foi a modificação mais eficaz, com melhorias consistentes nas principais métricas (precision, recall, F1-score).

O oversampling com jitter teve impacto mais reduzido e aumentou o risco de overfitting.

A accuracy isolada não é uma métrica fiável nestes cenários — métricas focadas na classe minoritária são mais informativas

KNN EM CONTEXTOS DE CLASS IMBALANCE



OBRIGADO